

理论准备：

多元函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在点 $x_0 = (x_1, x_2, \dots, x_n)$ 处可微，当且仅当存在一个关于点 x_0 的从线性空间 $\mathbb{R}^n$ 到线性空间 $\mathbb{R}$ 的线性映射 $L: \mathbb{R}^n \rightarrow \mathbb{R}$ 满足 $f(x_0 + h) = f(x_0) + L(h) + o(h)$ 这里的 $o(h)$ 是某个从 $\mathbb{R}^n$ 到 $\mathbb{R}$ 的函数，满足：

$$\lim_{h \rightarrow 0} \frac{o(h)}{\|h\|} = 0$$

下面说明函数 f 在 x_0 处的梯度向量的方向是函数 f 在 x_0 处的方向导数绝对值达到最大的方向，且该向量的模就是最大值。设 $u = (u_1, u_2, \dots, u_n) \in \mathbb{R}^n$ 且 $\|u\| = 1$ ，函数 f 在点 x_0 处沿单位向量 u 的方向导数为

$$\begin{aligned} \lim_{t \rightarrow 0} \frac{f(x_0 + tu) - f(x_0)}{t} &= \lim_{t \rightarrow 0} \frac{f(x_0) + L(tu) + o(tu) - f(x_0)}{t} \\ &= L(u) + \lim_{t \rightarrow 0} \frac{o(tu)}{t} \\ &= L(u) \\ &= \frac{\partial f}{\partial x_1} u_1 + \frac{\partial f}{\partial x_2} u_2 + \dots + \frac{\partial f}{\partial x_n} u_n \end{aligned}$$

应用 Cauchy-Schwarz 不等式，有

$$\left(\frac{\partial f}{\partial x_1} u_1 + \frac{\partial f}{\partial x_2} u_2 + \dots + \frac{\partial f}{\partial x_n} u_n \right)^2 \leq \left(\frac{\partial f}{\partial x_1} \right)^2 + \dots + \left(\frac{\partial f}{\partial x_n} \right)^2$$

可得

$$\left| \sum_{i=1}^n \frac{\partial f}{\partial x_i} u_i \right| \leq \sqrt{\left(\frac{\partial f}{\partial x_1} \right)^2 + \dots + \left(\frac{\partial f}{\partial x_n} \right)^2} = \left\| \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right) \right\| = \|\nabla f(x_0)\|$$

等号在向量 u 与梯度向量 $\left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)$ 共线时取得。多元函数求导的一些有用性质：

$$\nabla x' \alpha = \nabla \alpha' x = \alpha$$

$$\nabla x' A x = (A + A') x$$

$$\nabla \|x\|^2 = 2x$$

编程实践：

给定训练集 $\{(x^{(i)}, y^{(i)}) \mid i = 1, 2, \dots, n\}$ 其中 $x^{(i)} \in \mathbb{R}^d, y^{(i)} \in \mathbb{R}$ ，寻找 $\theta \in \mathbb{R}^{d+1}$ 使得均方误差 (MSE) 形式的损失函数 (cost function) 达到最小，这里

$$h_\theta(x) = \theta' \begin{pmatrix} 1 \\ x \end{pmatrix} = (\theta_0, \theta_1, \dots, \theta_d)(x_0, x_1, x_2, \dots, x_d)' \quad x_0 = 1$$

$$J(\theta) = J(\theta_0, \theta_1, \dots, \theta_d) = \frac{1}{2} \sum_{i=1}^n \left(h_\theta(x^{(i)}) - y^{(i)} \right)^2 = \frac{1}{2} \|X\theta - y\|_2^2$$

$$\begin{aligned}
\frac{\partial J}{\partial \theta_j} &= - \sum_{i=1}^n \left[h_{\theta}(x^{(i)}) - y^{(i)} \right] x_j^{(i)} = - \sum_{i=1}^n \left[\theta' x^{(i)} - y^{(i)} \right] x_j^{(i)} \\
&= -(x_j^{(1)}, x_j^{(2)}, \dots, x_j^{(n)}) \begin{pmatrix} \theta' x^{(1)} - y^{(1)} \\ \theta' x^{(2)} - y^{(2)} \\ \vdots \\ \theta' x^{(n)} - y^{(n)} \end{pmatrix}
\end{aligned}$$

于是我们就可以推导出梯度的表达式了

$$\nabla J = \begin{pmatrix} \frac{\partial J}{\partial \theta_0} \\ \frac{\partial J}{\partial \theta_1} \\ \vdots \\ \frac{\partial J}{\partial \theta_d} \end{pmatrix} = - \begin{pmatrix} x_0^{(1)} & x_0^{(2)} & \cdots & x_0^{(n)} \\ x_1^{(1)} & x_1^{(2)} & \cdots & x_1^{(n)} \\ x_2^{(1)} & x_2^{(2)} & \cdots & x_2^{(n)} \\ \vdots & \vdots & \ddots & \vdots \\ x_d^{(1)} & x_d^{(2)} & \cdots & x_d^{(n)} \end{pmatrix} \begin{pmatrix} \theta' x^{(1)} - y^{(1)} \\ \theta' x^{(2)} - y^{(2)} \\ \vdots \\ \theta' x^{(n)} - y^{(n)} \end{pmatrix} = -X'(y - X\theta)$$

我们要说明梯度下降法更新操作中为什么是 $\theta \leftarrow \theta - \alpha \nabla J(\theta)$ ，等号右侧表达式中为什么使用减号，而不是加号，给出如下的说明

$$\begin{aligned}
f(x_0 + t\nabla f(x_0)) - f(x_0) &= L(t\nabla f(x_0)) + r(t\nabla f(x_0)) \\
&= tL(\nabla f(x_0)) + r(t\nabla f(x_0)) \\
&= t \left[\left(\frac{\partial f}{\partial x_1} \right)^2 + \left(\frac{\partial f}{\partial x_2} \right)^2 + \cdots + \left(\frac{\partial f}{\partial x_n} \right)^2 \right] + r(t\nabla f(x_0)) \\
&= t\|\nabla f(x_0)\|^2 + r(t\nabla f(x_0))
\end{aligned}$$

已知函数 $r(h)$ 满足 $\lim_{h \rightarrow 0} \frac{r(h)}{\|h\|} = 0$ ，所以说有

$$\lim_{t \rightarrow 0^+} \frac{r(t\nabla f(x_0))}{t\|\nabla f(x_0)\|} = 0 \Rightarrow \lim_{t \rightarrow 0^+} \frac{r(t\nabla f(x_0))}{t\|\nabla f(x_0)\|^2} = 0$$

进而有

$$\forall \varepsilon > 0 \exists \delta(\varepsilon) > 0 \forall t \in (0, \delta(\varepsilon)) \left(\frac{|r(t\nabla f(x_0))|}{t\|\nabla f(x_0)\|^2} < \varepsilon \Rightarrow |r(t\nabla f(x_0))| < \varepsilon t\|\nabla f(x_0)\|^2 \right)$$

只需取 $\varepsilon = \frac{1}{2}$ ，我们便可以找到一正实数 δ_0 使得 $\forall t \in (0, \delta_0)$ $(-|r(t\nabla f(x_0))| > -\frac{1}{2}t\|\nabla f(x_0)\|^2)$ 如此便有

$$\begin{aligned}
f(x_0 + t\nabla f(x_0)) - f(x_0) &= t\|\nabla f(x_0)\|^2 + r(t\nabla f(x_0)) \\
&\geq t\|\nabla f(x_0)\|^2 - |r(t\nabla f(x_0))| \\
&> \frac{1}{2}t\|\nabla f(x_0)\|^2 \\
&> 0
\end{aligned}$$