

理论准备：

每个训练实例中的 $x^{(i)}$ 仍然是实数域上 n 维列向量空间 $\mathbb{R}^n$ 中的元素，但是 $y^{(i)}$ 却是集合 $\{0, 1\}$ 当中的元素，原先线性回归中的假设函数 $h_\theta(x)$ 被置为 $h_\theta(x) = \theta'x$ ，这次为了使函数值属于闭区间 $[0, 1]$ ，必须重新定义假设函数，我们令

$$h_\theta(x) = g(\theta'x) = \frac{1}{1 + e^{-\theta'x}},$$

可见对于任何 $x \in \mathbb{R}^n$ 都有 $h_\theta(x) \in (0, 1)$ ，这里的函数 $g(x) = \frac{1}{1+e^{-x}}$ 被称为 sigmoid 函数。关于参数 θ 的似然函数 $L(\theta)$ 被定义为

$$\begin{aligned} L(\theta) &= \prod_{i=1}^n p(y^{(i)} | x^{(i)}; \theta) \\ &= \prod_{i=1}^n \left(h_\theta(x^{(i)}) \right)^{y^{(i)}} \left(1 - h_\theta(x^{(i)}) \right)^{1-y^{(i)}} \end{aligned}$$

对它取对数，得到了形式更便于计算的关于参数 θ 的对数似然函数 $l(\theta)$

$$\begin{aligned} l(\theta) &= \ln L(\theta) \\ &= \sum_{i=1}^n y^{(i)} \ln [h_\theta(x^{(i)})] + (1 - y^{(i)}) \ln [1 - h_\theta(x^{(i)})] \end{aligned}$$

对数自然函数的梯度向量的分量可以表示为

$$\frac{\partial l}{\partial \theta_j} = \sum_{i=1}^n \left(y^{(i)} - h_\theta(x^{(i)}) \right) x_j^{(i)}$$

自然梯度向量就是

$$\nabla l(\theta) = X' \begin{pmatrix} y^{(1)} - h_\theta(x^{(1)}) \\ y^{(2)} - h_\theta(x^{(2)}) \\ \vdots \\ y^{(n)} - h_\theta(x^{(n)}) \end{pmatrix} = \begin{pmatrix} x_0^{(1)} & x_0^{(2)} & \cdots & x_0^{(n)} \\ x_1^{(1)} & x_1^{(2)} & \cdots & x_1^{(n)} \\ x_2^{(1)} & x_2^{(2)} & \cdots & x_2^{(n)} \\ \vdots & \vdots & \ddots & \vdots \\ x_d^{(1)} & x_d^{(2)} & \cdots & x_d^{(n)} \end{pmatrix} \begin{pmatrix} y^{(1)} - h_\theta(x^{(1)}) \\ y^{(2)} - h_\theta(x^{(2)}) \\ \vdots \\ y^{(n)} - h_\theta(x^{(n)}) \end{pmatrix}$$

梯度上升算法的参数更新步骤变为了 $\theta \leftarrow \theta + \alpha \nabla l(\theta)$

对求取函数零点的 Newton Method 进行推广可以得到一种新的寻找 $\hat{\theta}$ 的方法，这里的 $\hat{\theta}$ 满足 $l(\hat{\theta}) = \max_{\theta} l(\theta)$

$$x \leftarrow x - \frac{f(x)}{f'(x)}$$

以上是一般的 Newton Method 的更新步骤，下面是推广之后的更新步骤

$$\theta \leftarrow \theta - H^{-1}(\theta) \nabla l(\theta)$$

其中， $H \in M_{d \times d}(\mathbb{R})$ ($H_{ij} = \frac{\partial^2 l}{\partial \theta_i \partial \theta_j} = l_{ji}$) 称为黑塞矩阵 (Hessian matrix)。